

CENTRO DE ENSEÑANZA TÉCNICA Y SUPERIOR



Materia:

Mineria de Datos

Profesor:

Miguel Gonzalez Marquez

Actividad:

Extendiendo el Modelo Multidimensional

Estudiante:

Rhamses Orozco Talamantes e012705

Ensenada, B.C, a 22 de septiembre de 2026

El espacio vectorial de las imágenes:

Una imagen digital a color no es un vector plano de entrada, sino que se puede representar como un tensor de rango 3 con dimensiones de $256 * 256 * 3$ (el 3 refiriéndose a los RGB).

Cada elemento del arreglo contiene la intensidad de luz del pixel, que normalmente son valores de 0 a 255 o también pueden ser flotantes de 0.0 a 1.0

También se puede calcular el número de dimensiones en una imagen usando la fórmula anterior. Para que los algoritmos clásicos o con capas densas puedan llegar a procesar la imagen como una fila dentro de la matriz de diseño, la imagen se aplanan en un vector de una sola dimensión, siendo $256*256*3 = 196608$ dimensiones

El espacio vectorial del texto:

El algoritmo necesita números porque la distancia euclidiana no funciona sobre un texto crudo, aquí se resuelve de dos maneras principales:

- TF-IDF: Este crea un vector con el tamaño total del vocabulario. Cada entrada indica que tan frecuente e informativa es la palabra en el texto.
- Sentence embeddings: Estos proyectan cada palabra a un espacio vectorial continuo de menor dimensión. Se basan en la hipótesis distribucional, ósea palabras que aparecen en contextos similares tienen significados similares. La ventaja es que las palabras con significados afines terminan con coordenadas cercanas en el espacio vectorial, así permitiendo realizar aritmética de conceptos.

La maldición de la dimensionalidad:

En la estadística y ML, cuando el número de variables p crece drásticamente respecto al número de muestras, la geometría del espacio se comporta de forma contraintuitiva.

- Concentración de distancias: A medida que p tiende a infinito, la distancia euclidiana entre dos puntos que sea tiende a hacerse igual.
- Pérdida del concepto de vecino cercano: El volumen del espacio crece de forma exponencial. Los datos quedan extremadamente dispersos en un vacío hiperdimensional. Algoritmos basados en distancias como KNN colapsan porque ya no existen observaciones realmente cercanas a un punto nuevo

